Flyt MPS 성능 간섭 비교 — 초기화 실패 및 측정 미완료 보고서

2026-10-26 KST. **Flyt 유효 측정 0구간 / 계획 30구간. 성능 차이 계산 불가.**

Flyt SHM 경로로 기존 MLP를 실행하려 했으나 PyTorch import에서 중단됐다. 기존 VMWeave 자료는 재집계했고 신규 GPU 재측정은 하지 않았다. 아래 값은 기존 VMWeave 실측값이며 Flyt 결과가 아니다. N/A는 0% 또는 무간섭을 뜻하지 않는다.

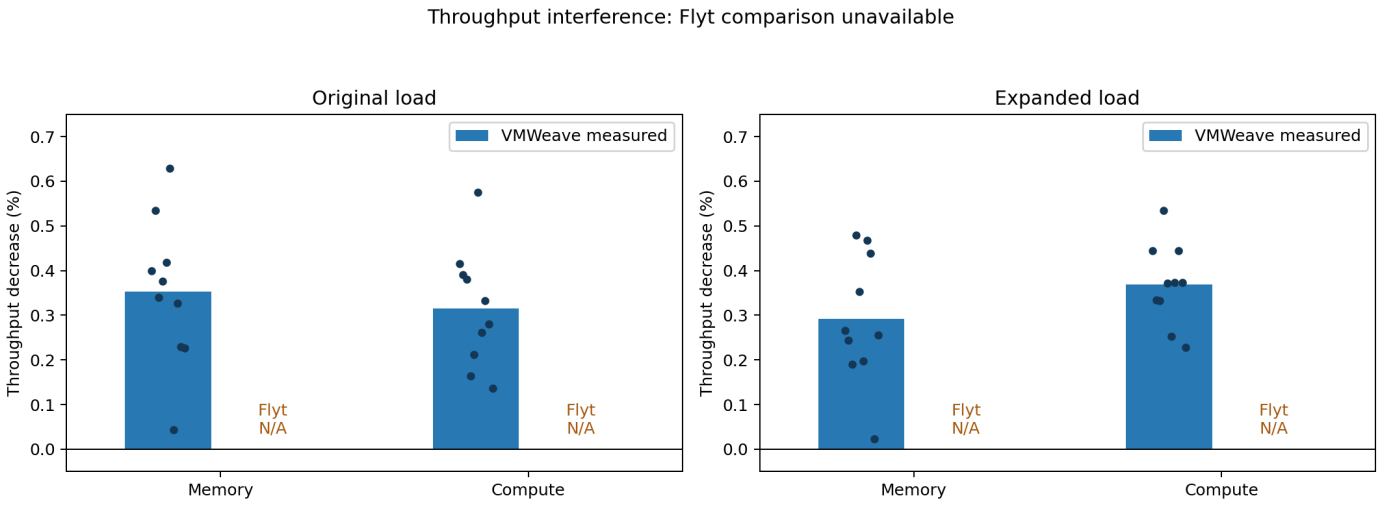
실행 결과와 근거

1. 두 시험 VM(각 8 vCPU/16GiB RAM)과 분리된 Flyt 백엔드·SHM backing을 준비했다. 대상 GPU는 RTX PRO 6000 Blackwell Server Edition, 드라이버 580.173.02다.
2. 같은 MPS 데몬을 두 백엔드가 사용하도록 구성했다. A 백엔드 로그에는 94 SM 및 2GiB 요청과 virtual server 초기화가 기록됐다. GPU 컨텍스트의 실제 SM 제한과 메모리 한도 강제 적용, 두 VM의 동시 MLP 실행은 검증 단계에 도달하지 못했다.
3. 기존 Rodinia 방식으로 Flyt 클라이언트를 `libcudart.so.12`로 로딩하면 `libc10_cuda.so`에서 `cudaGetDriverEntryPointByVersion` 심볼을 찾지 못해 PyTorch import가 실패했다. 원시 오류, 심볼 점검을 보존했다. 해당 심볼 부재는 확인했으나 이것이 유일한 호환성 문제라고 단정하지 않는다.
4. 제품 변경 없이 실제 CUDA runtime과 Flyt LD_PRELOAD를 함께 사용하는 대체 설정을 진단했다. A의 재사용 백엔드와 B의 새 백엔드 모두 40초 내 초기화를 마치지 못했고 종료 코드 124였다. 두 진단의 출력은 0바이트이며 timeout 내부 원인은 미확인이다. 진단 상태. 이들은 성능 반복으로 세지 않는다.
5. 사전 승인된 실패 중단 기준에 따라 남은 반복을 실행하지 않았다. 웜업·별도 성능 파일럿·p99 분석·제품 코드 수정은 수행하지 않았다. 시험 환경 정리 결과는 cleanup.json에 기록한다.

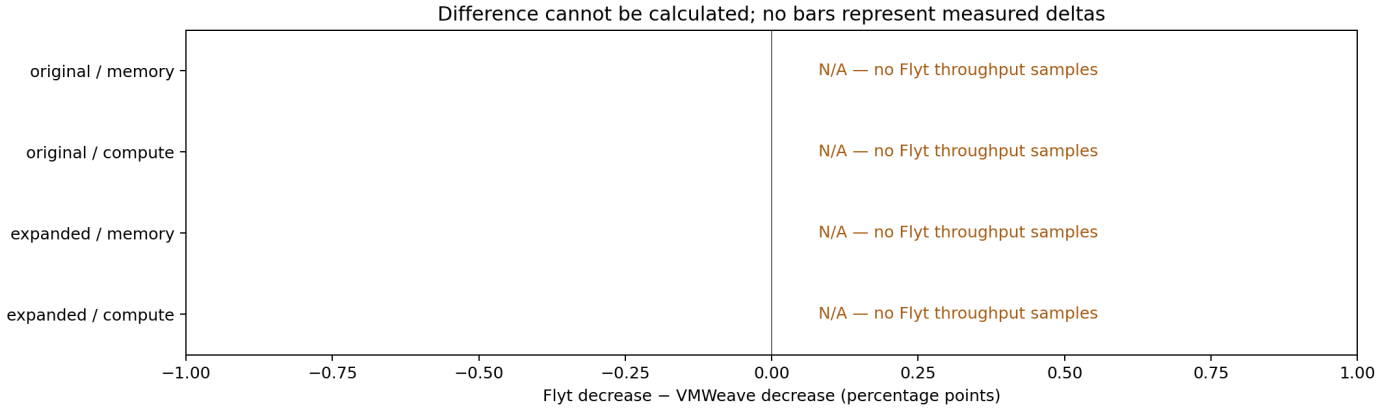
처리량 감소율 비교

D = 100 × (1 − 동시 부하 처리량 / 동일 반복 baseline 처리량). 표는 반복별 D의 동일 가중 평균이다. ΔD = Flyt 평균 D − 기존 VMWeave 평균 D (%p).

부하 규모	상대 부하	기존 VMWeave 감소율	신규 Flyt	차이(%p)
original	memory	0.352%	N/A	N/A
original	compute	0.315%	N/A	N/A
expanded	memory	0.291%	N/A	N/A
expanded	compute	0.369%	N/A	N/A

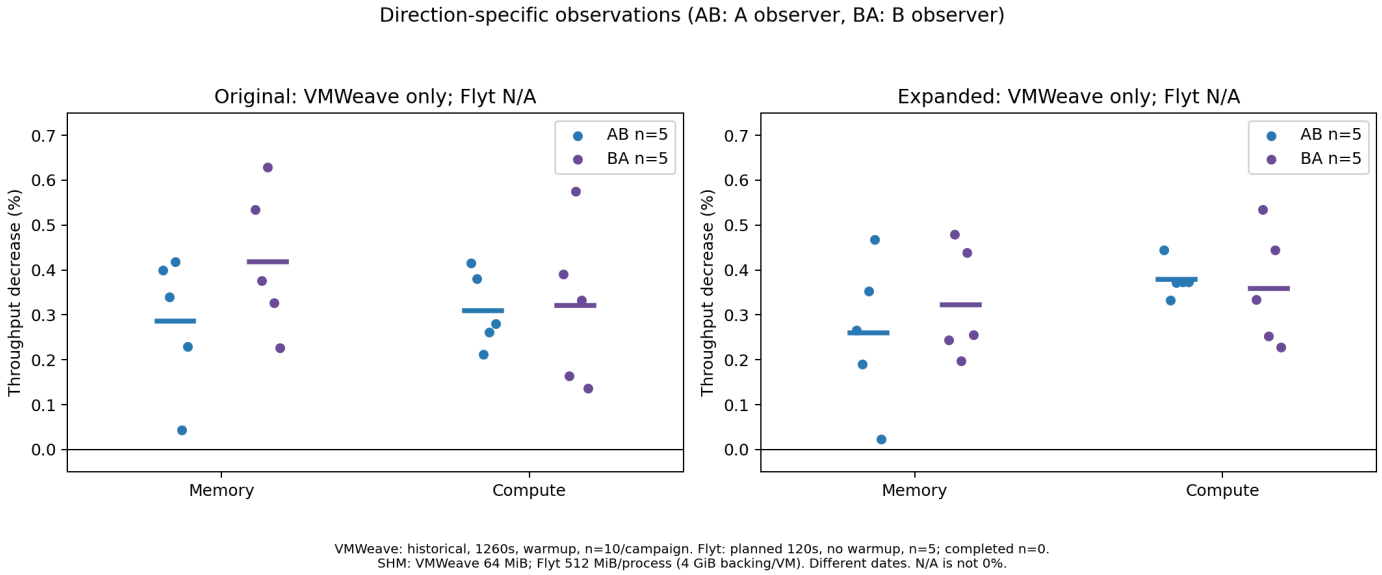


VMWeave: historical, 1260s, warmup, n=10/campaign. Flyt: planned 120s, no warmup, n=5; completed n=0.
SHM: VMWeave 64 MiB; Flyt 512 MiB/process (4 GiB backing/VM). Different dates. N/A is not 0%.



VMWeave: historical, 1260s, warmup, n=10/campaign. Flyt: planned 120s, no warmup, n=5; completed n=0.
SHM: VMWeave 64 MiB; Flyt 512 MiB/process (4 GiB backing/VM). Different dates. N/A is not 0%.

방향별 결과와 변동



기존 VMWeave는 각 캠페인 AB/BA 각각 5회다. 전체 반복 점과 방향별 평균을 표시했다. 신규 Flyt는 유효 반복이 없어 평균·표준편차·방향 가중 결과를 계산하지 않는다. 반복별 기존 자료, 방향별 집계, 비교 집계에 원시 정밀도 수치를 제공한다. 통계적 유의성이나 시스템 우열은 판정하지 않는다.

절대 처리량 — 감소율 해석용 기존 참고값

규모	조건	기존 VMWeave 평균 처리량(건/초)	Flyt
original	baseline	10.1266	N/A
original	memory	10.0909	N/A
original	compute	10.0946	N/A
expanded	baseline	10.1016	N/A
expanded	memory	10.0721	N/A
expanded	compute	10.0643	N/A

비교 조건과 제한

항목	기존 VMWeave	계획/준비한 Flyt
측정 기간	조건당 1260초	목표 120초; 실제 측정 시작 못함
반복	원/확대 각각 10회	각각 5회 계획; 완료 0회
웜업	수행	생략 계획; 실행도 없음
워크로드	FP32 eager MLP 1024→2048→1024, batch32	동일 소스 기반, import 실패
자원	VM별 8 vCPU/16GiB, 연산 50%/2GiB	같은 VM 크기, 외부 50%/2GiB 및 Flyt 94 SM/2GiB 요청; 실제 강제 적용 미검증
SHM	64MiB	사용자 승인한 512MiB/process, VM별 4GiB backing
시점	2026-10-12~14	2026-10-26 준비/실패 진단

처리량은 결과 D2H 전송·CPU 검증·로그 비용을 포함하는 기존 관측 루프 기준이다. 제품 경로·시점·웜업·관측 길이·SHM 차이가 있으므로 유효 측정을 얻더라도 MPS만의 효과로 귀속할 수 없다. 이번에는 유효 Flyt 값 자체가 없으므로 성능 우열·간섭 크기·무간섭에 관한 결론을 낼 수 없다. Rodinia 성공이 이 PyTorch 번들의 호환성을 보장하지 않음을 확인했다.

재현 및 파일 안내

저장소 루트에서 Python과 `matplotlib==3.9.4`, `Markdown==3.10.2`를 준비한 뒤 다음 명령으로 공개 증거의 해시 검증, 기존 결과 재집계, PNG/SVG/PDF 그래프, Markdown/독립 HTML 보고서를 재생성한다. GPU·클러스터 접근은 하지 않는다.

```
python3 experiments/thesis-
isolation/runner/analyze_flyt_mps_comparison.py
```

PDF 보고서, manifest, protocol, 입력 해시, 검증. 그래프는 `figures/`의 PNG/SVG/PDF로 제공한다. HTML은 그래프를 내장한다. PDF 보고서는 생성된 HTML을 Chromium의 headless print-to-pdf로 출

력한 추가 배포본이며 위 집계 명령은 PDF 보고서를 재생성하지 않는다(그래프 PDF는 재생성한다). 전체 클러스터 로그·자격증명·대형 바이너리는 공개에서 제외했다. 실행 계획의 측정 조건과 중단 기준을 따른다.

다음 측정을 위해서는 동일 PyTorch 번들을 지원하는 Flyt CUDA API 경로를 확보하고 초기화를 확인해야 한다. 제품 API 구현 변경이나 다른 PyTorch/워크로드로 전환하는 후속 작업은 이번 결과에 포함하지 않았다.