호환 패치 Flyt MPS와 기존 VMWeave의 처리량 간섭 비교

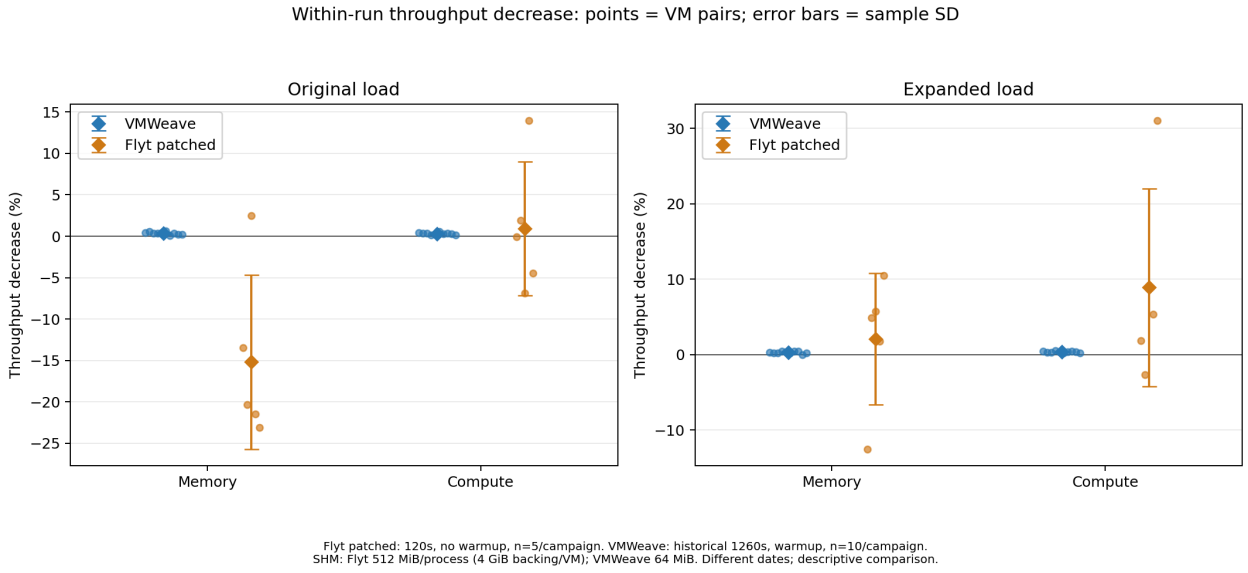
Flyt 신규 10개 독립 VM 쌍·30구간을 완료했다. 원/확대 캠페인별 총 5회이며, 기존 VMWeave 각 10회 전체와 비교했다. 정상 완료 요청은 **79,511건**, 요청 오류·정확성 불일치는 **0건**이다. 최대 절대 오차는 5.81145287e-07이며 기존 rtol=1e-4, atol=1e-6 검사를 유지했다. 네 조건의 Flyt 평균 감소율은 -15.173~+8.913%이며, 기존 VMWeave와의 차이는 -15.526~+8.545%p다. 수치는 각 반복의 baseline 대비 감소율을 평균한 기술적 비교다.

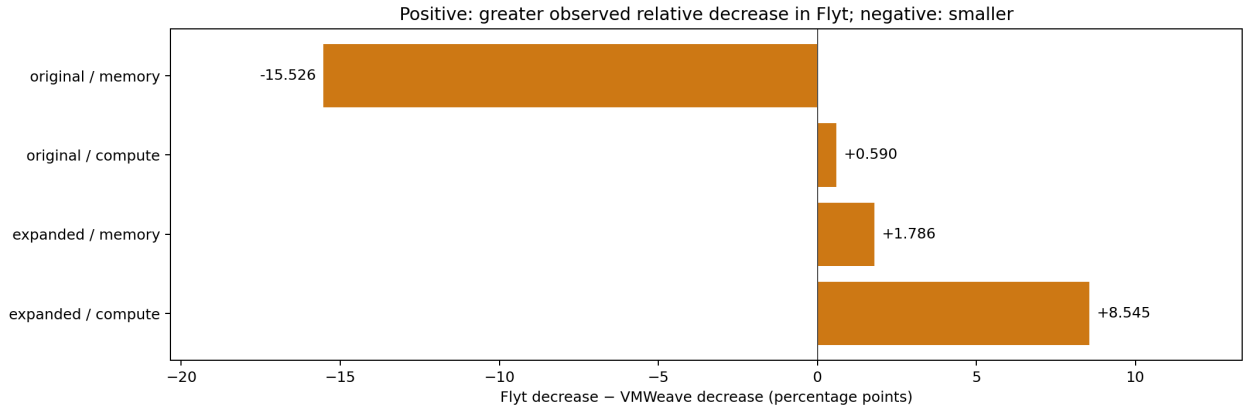
처리량 감소율

캠페인	부하	VMWeave 감소율(%)	Flyt 감소율(%)	ΔD(%p)	Flyt SD / 최소 / 최대(%)
original	memory	0.352	-15.173	-15.526	10.508 / -23.065 / 2.447
original	compute	0.315	0.905	+0.590	8.079 / -6.860 / 13.961
expanded	memory	0.291	2.077	+1.786	8.727 / -12.504 / 10.472
expanded	compute	0.369	8.913	+8.545	13.106 / -2.685 / 31.049

D=100×(1−동시 부하 처리량/같은 반복 baseline 처리량), ΔD=평균 D(Flyt)−평균 D(VMWeave). 감소율 단위는 %, 차이 단위는 %p다. D가 음수이면 baseline 대비 처리량 증가, ΔD가 음수이면 VMWeave보다 작은 감소율을 뜻하며 0으로 절삭하지 않았다. SD는 요청 단위가 아닌 독립 VM 쌍 간 표본 표준편차다.

Flyt의 네 조건 표본 SD는 8.079~13.106%p로, 기존 VMWeave의 0.091~0.165%p보다 컸다. 확대 연산 부하의 평균 감소율이 가장 컸지만 개별 반복에는 처리량 증가도 있어 일관된 감소라고 단정하지 않는다. 원 메모리 부하의 음수 평균도 동시 실행의 인과적 이득을 입증하지 않는다. 웜업 생략·짧은 관측·실제 부하량 등 조건 차이와 반복 변동을 함께 고려해야 한다.



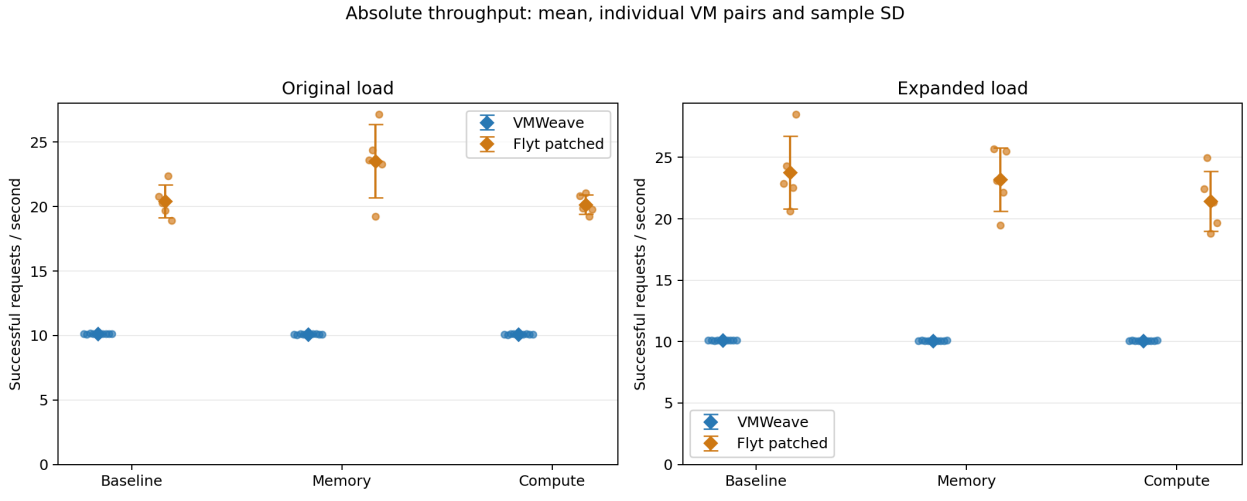


Flyt patched: 120s, no warmup, n=5/campaign. VMWeave: historical 1260s, warmup, n=10/campaign.
SHM: Flyt 512 MiB/process (4 GiB backing/VM); VMWeave 64 MiB. Different dates; descriptive comparison.

절대 처리량과 부하의 실제 실행량

캠페인	시스템	baseline (건/초)	memory (건/초)	compute (건/초)
original	VMWeave	10.127	10.091	10.095
original	호환 패치 Flyt	20.414	23.535	20.152
expanded	VMWeave	10.102	10.072	10.064
expanded	호환 패치 Flyt	23.770	23.189	21.434

baseline도 두 VM을 준비한 상태에서 상대 VM이 유휴인 조건이다. 처리량은 결과 검증을 마친 정상 완료 수/전체 관측 경과 시간이며, 실행 시간이 목표 120초를 조금 넘으면 실제 경과 시간을 사용했다. 두 시스템의 절대 처리량 차이와 상대 감소율은 구분해야 한다.



Flyt patched: 120s, no warmup, n=5/campaign. VMWeave: historical 1260s, warmup, n=10/campaign.
SHM: Flyt 512 MiB/process (4 GiB backing/VM); VMWeave 64 MiB. Different dates; descriptive comparison.

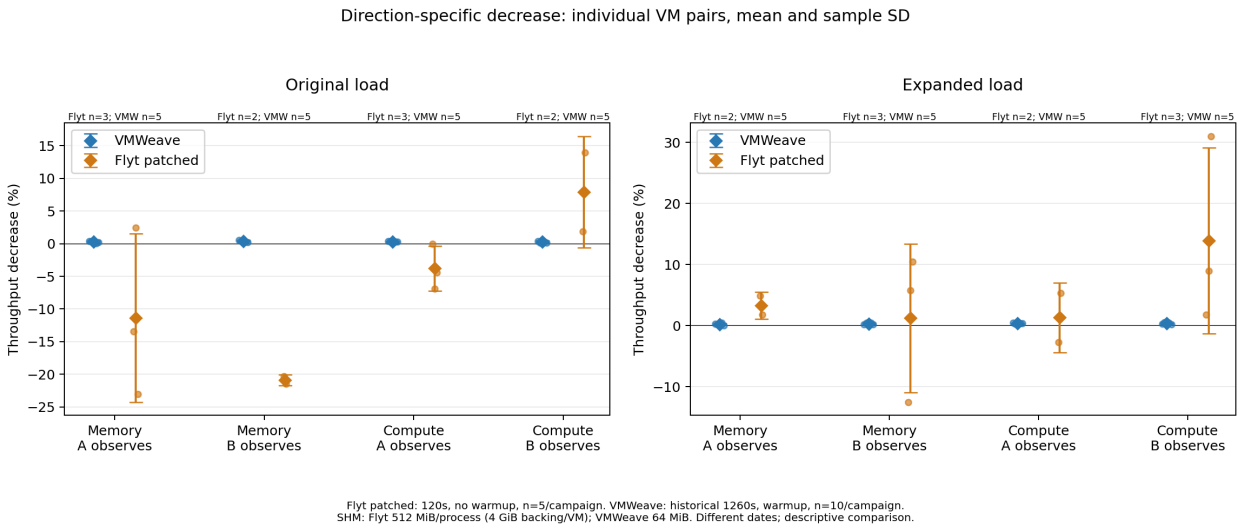
캠페인	부하	VMWeave 실제 부하 (커널/초)	Flyt 실제 부하 (커널/초)
original	memory	69.24	176.31

캠페인	부하	VMWeave 실제 부하 (커널/초)	Flyt 실제 부하 (커널/초)
original	compute	45.83	140.09
expanded	memory	116.62	256.25
expanded	compute	62.27	38.37

부하 실행량은 각 부하의 실제 전체 실행 구간에서 완료 커널 수/경과 시간으로 계산했다. Flyt 부하 목표 130초, 관측 목표 120초이며 준비 이후 부하가 관측 종료까지 계속됐음을 기록으로 확인했다. 기존 VMWeave 부하도 보관된 load 완료 기록으로 재집계했다. 커널/초는 시스템 간 동일한 GPU 점유율을 뜻하지 않는다. 제출 경로·작업 배출 속도 차이는 간섭률 해석에 포함해야 한다. GPU/CPU 원시 telemetry는 입력 manifest와 raw 자료에 보존했다.

방향과 반복 변동

캠페인	부하	Flyt 반복 동일 가중(%)	Flyt 방향 50:50(%)	50:50 ΔD(%p)
original	memory	-15.173	-16.126	-16.478
original	compute	0.905	2.076	+1.761
expanded	memory	2.077	2.287	+1.995
expanded	compute	8.913	7.652	+7.284



원 P는 A 관측 3회/B 관측 2회, 확대 P는 A 2회/B 3회다. 주 결과는 5회 동일 가중이며 방향 50:50은 보조 결과다. 개별 5회 전체는 flyt-per-run.csv, 방향별 표본 수·SD·최솟값·최댓값은 direction-comparison.csv에 있다. 2~3회 방향 표본에 bootstrap 구간이나 유의성 검정을 붙이지 않았다.

비교 조건과 해석 범위

항목	신규 Flyt	기존 VMWeave
모델	FP32 eager MLP 1024→2048→1024, batch 32, seed 20261012	동일

항목	신규 Flyt	기존 VMWeave
Python / PyTorch / CUDA	기존 번들 복사본: 3.10.12 / 2.11.0+flyt.cu128 / 12.8	기존 번들
GPU / 자원	같은 GPU UUID, 94 SM 요청·실효 조회 94, 2GiB 제한, VM 8vCPU·16GiB	기존 기록의 조건; 재측정 없음
원/확대 부하	128MiB/1024MiB 버퍼, 1024^2/8192^2 행렬, 동기화 규칙 유지	동일 작업 정의
SHM	프로세스당 512MiB, VM별 backing 4GiB	64MiB
반복 / 관측	캠페인별 5회 / 조건당 120초	캠페인별 10회 / 조건당 1260초
웜업	없음; 첫 요청과 초기 비용 포함	기존 웜업 있음
소프트웨어	**실험용 호환 패치 적용 Flyt**	기존 보관 결과

Flyt 패치는 진입점 조회, PCI 탐색, 내부·구조체 포인터 보존, 필요 커널의 지연 조회를 포함한다. 실제 GPU 가상주소를 보존하는 이 시험 빌드는 체크포인트·이동을 명시적으로 거부하며, 일반 배포 또는 모든 CUDA API 지원을 검증한 것이 아니다. 호환성 복구 보고서에 근거·패치·검증·제한을 분리했다. 기존 VMWeave 패키지와 결과는 수정하거나 삭제하지 않았다.

원 P 첫 세 반복은 부하 커널 동기화 후 완료 이벤트를 받았지만, 그 뒤 버퍼 삭제·캐시 회수까지의 별도 확인 응답은 없었다. 나머지 7회에는 대기열에 `observe 0` 제어 명령을 보내 회수 뒤 응답을 확인했다(요청 0개, GPU 연산 없음). 첫 세 반복의 조건 전환 시 회수 작업 중첩 여부는 로그만으로 확정할 수 없다. 해당 표본을 제외·재측정하지 않고 모두 주 집계에 포함했으며, 이는 절차 차이와 해석 제한이다.

ΔD는 이번 조건에서 관측한 차이이며, MPS 자체의 인과 효과나 시스템의 일반적 우열을 확정하지 않는다. 측정 시점, 실행 경로, 실제 부하량, 웜업, 관측 길이, SHM 및 호환 패치 차이가 함께 포함된다. 작은 차이나 음수 감소율을 무간섭·동등성으로 해석하지 않는다. 본문·도표에 지연시간 백분위수 비교는 포함하지 않았다. 기존 요청 기록의 start/latency는 결과 검증·출력까지의 정확한 완료 시각을 제공하지 않으므로 과거 첫 120초를 잘라 별도 표본으로 사용하지 않았다.

방법·검증·재현

- 각 반복은 새 VM 쌍과 독립 세션을 사용했다. 3조건 순서는 고정 seed로 사전 결정하고 가능한 범위에서 위치를 균형화했다. protocol.json에 방향과 순서를 모두 기록했다.
- 진단·호환성 검증은 본실험에 합산하지 않았다. VMWeave는 신규 실행하지 않았으며 원본 각 10회를 임의 선별하지 않았다.
- 원시 요청 수, 정확성 코드, 경과 시간, 부하 완료·관측 종료 순서와 CSV를 교차 검산했다. validation.json, cleanup.json, source-sha256.json을 참조한다.
- 그래프는 같은 CSV/JSON에서 PNG·SVG·PDF로 생성했다. 오차 막대는 표본 SD이며 신뢰구간이 아니다.

저장소 루트에서 Python 환경에 matplotlib와 Markdown을 설치한 뒤 다음 읽기 전용 명령으로 보고서·표·그래프를 재생성한다.

```
python3 experiments/thesis-isolation/runner/analyze_flyt_mps_recovered.py
```

comparison.csv · comparison.json · VMWeave 전체 참조 · 부하 실행량 · HTML 보고서 · PDF 보고서